

# Causal Networks

Giuseppe Magazzù

2021 - 2022

# Contents

<b>1</b>	<b>The Potential Outcome Framework</b>	<b>1</b>
1.1	Potential Outcome . . . . .	1
<b>2</b>	<b>Flow of Associations and Causal Graphs</b>	<b>3</b>
2.1	Bayesian Networks . . . . .	4
2.2	Causal Networks . . . . .	4
2.3	D-Separation . . . . .	5
<b>3</b>	<b>Causal Models</b>	<b>6</b>
<b>4</b>	<b>Structural Causal Models</b>	<b>7</b>
<b>5</b>	<b>Randomized Experiments</b>	<b>8</b>
<b>6</b>	<b>Nonparametric Identification</b>	<b>9</b>
<b>7</b>	<b>Estimation</b>	<b>10</b>
<b>8</b>	<b>Unobserved Confounding</b>	<b>11</b>
<b>9</b>	<b>Instrumental Variables</b>	<b>12</b>
<b>10</b>	<b>Causal Discovery from Observational Data</b>	<b>13</b>
<b>11</b>	<b>Transfer Learning and Transportability</b>	<b>14</b>
<b>12</b>	<b>Counterfactuals</b>	<b>15</b>

# Chapter 1

## The Potential Outcome Framework

Fundamental Problem of Causal Inference:

- Average Treatment Effects and Missing Data Interpretation
- Ignorability - Exchangeability
- Conditional Exchangeability - Uncounfoundedness
- Positivity - Overlap - Common Support and Extrapolation
- No interference, Consistency, SUTVA

### 1.1 Potential Outcome

- $X$  **Treatment** variabile aleatoria
- $Y$  **Outcome** variabile aleatoria
- $Z$  **Covariate** insieme di variabili aleatorie

Il **potential outcome**  $Y(x)$  denota quale sarebbe l'**outcome** quando  $X = x$ , ovvero se il treatment che è stato scelto è  $x$ . Una volta che viene osservato il **potential outcome**  $Y(x)$  questo assume valore  $Y$  chiamato **outcome**.

Una **popolazione** consiste di molti individui o unità. Ogni individuo (unità) è associato a uno o più variabili  $Z$  **covariate**.

Denotiamo  $X, Y, Z$  dell'individuo  $i$ -esimo come  $X_i, Y_i, Z_i$ .

$Y(x)$  è una variabile aleatoria

$Y_i(x)$  non è trattata come una variabile aleatoria poiché specifica per l'individuo

### Individual Treatment Effect (ITE)

Per verificare se c'è una relazione causale tra  $X$  e  $Y$  si può calcolare la seguente differenza  $\tau_i \triangleq Y_i(1) - Y_i(0)$ .

Se il potential outcome è uguale in entrambi i casi ( $\tau_i = 0$ ) allora non c'è relazione causale. Nel caso contrario si può notare che diversi treatment portano a diversi outcome e quindi c'è una relazione causale.

Non possiamo osservare tutti i **potential outcome** poiché l'osservarne uno influenzerebbe gli altri. I **potential outcome** che non possono essere osservati vengono chiamati **counterfactual**, mentre quello che osserviamo è il **factual**.

$Y(1) = ?$	$\Rightarrow$	$Y = 0, X = 1$	$\Rightarrow$	$Y(1) = ?$	counterfactual
$Y(0) = ?$	$\Rightarrow$	$Y = 0, X = 0$	$\Rightarrow$	$Y(0) = 1$	factual


### Average Treatment Effect (ATE)

$$\tau \triangleq \mathbb{E}[Y_i(1) - Y_i(0)]$$

## Chapter 2

# Flow of Associations and Causal Graphs

In un grafo diretto indichiamo con  $pa(X)$  i **genitori** del nodo  $X$  e  $ch(Y)$  i **figli** del nodo  $Y$ .




Un **cammino** è una qualsiasi sequenza di nodi adiacenti, indipendentemente dalla direzione degli archi che li collega.

Un **cammino diretto** è un qualsiasi **cammino** tra due nodi in cui tutti gli archi che li collega hanno la stessa direzione.

$de(Y)$  è l'insieme dei nodi **discendenti** del nodo  $Y$ , ovvero tutti i nodi che possono essere raggiunti da  $Y$ .

$an(Z)$  è l'insieme dei nodi **antenati** del nodo  $Z$ , ovvero tutti i nodi che da  $Z$  possono essere raggiunti.



## 2.1 Bayesian Networks

In una rete bayesiana vogliamo modellare la distribuzione di probabilità  $P(X_1, \dots, X_n)$ . Tramite la **Chain Rule** possiamo riscriverla nel seguente modo:

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \cdots P(X_n|X_1, \dots, X_{n-1}) \\ &= P(X_1) \prod_{i=2}^n P(X_i|X_1, \dots, X_{i-1}) \end{aligned}$$

**Local Markov Assumption:** Un nodo  $X$  è indipendente da tutti i suoi non-discendenti date l'evidenze di tutti i nodi genitori  $pa(X)$ .

Data questa assunzione possiamo applicare la fattorizzazione della probabilità  $P$ .

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i|pa(X_i))$$

In questo modo possiamo ridurre il numero di parametri della rete.

Una distribuzione di probabilità  $P$  si dice che sia Markov se ogni nodo  $X$  rispetta la Local Markov Assumption.

L'assunzione di Markov non ci da informazioni riguardo relazioni di dipendenza tra i nodi. Quindi estendiamo quest'assunzione.

### Minimality Assumption

- Dato  $pa(X)$ , un nodo  $X$  è indipendente da tutti i suoi non-discendenti.
- I nodi adiacenti sono dipendenti.

Dato un DAG  $G$ , se  $P$  è Markov allora sappiamo:


- $P$  soddisfa un insieme di indipendenze specificate dalla struttura di  $G$ .
- se  $P$  soddisfa pure la Minimality Assumption, allora l'insieme di indipendenze è minimale, ovvero  $P$  non soddisfa altre indipendenze in  $G$ . Questo equivale a dire che tutti i nodi adiacenti sono dipendenti.

## 2.2 Causal Networks

Una variabile  $X$  si dice **causa** di una variabile  $Y$  se  $Y$  può cambiare in risposta a un cambiamento di  $X$ .

**Causal Edge Assumption:** Ogni variabile associata a un nodo è causata dalle variabili dei nodi genitori.

Un **Grafo Causale** è un DAG in cui è soddisfatta la proprietà **Causal Edge Assumption**.



$X_1$  causa direttamente  $X_2$  e  $X_3$

$X_2$  causa direttamente  $X_3$

$X_3$  causa direttamente  $X_4$

$X_1$  causa indirettamente  $X_4$

### Association Flow

Chain, Fork, Collider, ...

## 2.3 D-Separation

## **Chapter 3**

# **Causal Models**



## **Chapter 4**

# **Structural Causal Models**

## **Chapter 5**

# **Randomized Experiments**

## **Chapter 6**

# **Nonparametric Identification**

## **Chapter 7**

# **Estimation**

## **Chapter 8**

# **Unobserved Confounding**

## **Chapter 9**

# **Instrumental Variables**

## **Chapter 10**

# **Causal Discovery from Observational Data**

## **Chapter 11**

# **Transfer Learning and Transportability**



## **Chapter 12**

# **Counterfactuals**