

Causal Networks

Giuseppe Magazzù

2021 - 2022

Contents

1	The Potential Outcome Framework	1
1.1	Potential Outcome	1
2	Flow of Associations and Causal Graphs	3
2.1	Bayesian Networks	4
2.2	Causal Networks	4
2.3	D-Separation	5
3	Causal Models	7
4	Structural Causal Models	8
5	Randomized Experiments	9
6	Nonparametric Identification	10
7	Estimation	11
8	Unobserved Confounding	12
9	Instrumental Variables	13
10	Causal Discovery from Observational Data	14
11	Transfer Learning and Transportability	15
12	Counterfactuals	16

Chapter 1

The Potential Outcome Framework

Fundamental Problem of Causal Inference:

- Average Treatment Effects and Missing Data Interpretation
- Ignorability - Exchangeability
- Conditional Exchangeability - Uncounfoundedness
- Positivity - Overlap - Common Support and Extrapolation
- No interference, Consistency, SUTVA

1.1 Potential Outcome

- X **Treatment** variabile aleatoria
- Y **Outcome** variabile aleatoria
- Z **Covariate** insieme di variabili aleatorie

Il **potential outcome** $Y(x)$ denota quale sarebbe l'**outcome** quando $X = x$, ovvero se il treatment che è stato scelto è x . Una volta che viene osservato il **potential outcome** $Y(x)$ questo assume valore Y chiamato **outcome**.

Una **popolazione** consiste di molti individui o unità. Ogni individuo (unità) è associato a uno o più variabili Z **covariate**.

Denotiamo X, Y, Z dell'individuo i -esimo come X_i, Y_i, Z_i .

$Y(x)$ è una variabile aleatoria

$Y_i(x)$ non è trattata come una variabile aleatoria poiché specifica per l'individuo

Individual Treatment Effect (ITE)

Per verificare se c'è una relazione causale tra X e Y si può calcolare la seguente differenza $\tau_i \triangleq Y_i(1) - Y_i(0)$.

Se il potential outcome è uguale in entrambi i casi ($\tau_i = 0$) allora non c'è relazione causale. Nel caso contrario si può notare che diversi treatment portano a diversi outcome e quindi c'è una relazione causale.

Non possiamo osservare tutti i **potential outcome** poiché l'osservarne uno influenzerebbe gli altri. I **potential outcome** che non possono essere osservati vengono chiamati **counterfactual**, mentre quello che osserviamo è il **factual**.

$Y(1) = ?$	\Rightarrow	$Y = 0, X = 1$	\Rightarrow	$Y(1) = ?$	counterfactual
$Y(0) = ?$	\Rightarrow	$Y = 0, X = 0$	\Rightarrow	$Y(0) = 1$	factual


Average Treatment Effect (ATE)

$$\tau \triangleq \mathbb{E}[Y_i(1) - Y_i(0)]$$

Chapter 2

Flow of Associations and Causal Graphs

In un grafo diretto indichiamo con $pa(X)$ i **genitori** del nodo X e $ch(Y)$ i **figli** del nodo Y .




$$\begin{aligned} pa(Y) &= \emptyset & ch(Y) &= \{X, Z\} \\ pa(X) &= Y & ch(X) &= \emptyset \end{aligned}$$

Un **cammino** è una qualsiasi sequenza di nodi adiacenti, indipendentemente dalla direzione degli archi che li collega.

Un **cammino diretto** è un qualsiasi **cammino** tra due nodi in cui tutti gli archi che li collega hanno la stessa direzione.

$de(Y)$ è l'insieme dei nodi **discendenti** del nodo Y , ovvero tutti i nodi che possono essere raggiunti da Y .

$an(Z)$ è l'insieme dei nodi **antenati** del nodo Z , ovvero tutti i nodi che da Z possono essere raggiunti.



$$\begin{aligned} an(Z) &= \{X, Y\} \\ an(Y) &= \emptyset \end{aligned}$$

$$\begin{aligned} de(Y) &= \{X, Z, W\} \\ de(W) &= \emptyset \end{aligned}$$

2.1 Bayesian Networks

In una rete bayesiana vogliamo modellare la distribuzione di probabilità $P(X_1, \dots, X_n)$. Tramite la **Chain Rule** possiamo riscriverla nel seguente modo:

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \cdots P(X_n|X_1, \dots, X_{n-1}) \\ &= P(X_1) \prod_{i=2}^n P(X_i|X_1, \dots, X_{i-1}) \end{aligned}$$

Local Markov Assumption: Un nodo X è indipendente da tutti i suoi non-discendenti date l'evidenze di tutti i nodi genitori $pa(X)$.

Data questa assunzione possiamo applicare la fattorizzazione della probabilità P .

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i|pa(X_i))$$

In questo modo possiamo ridurre il numero di parametri della rete.

Una distribuzione di probabilità P si dice che sia Markov se ogni nodo X rispetta la Local Markov Assumption.

L'assunzione di Markov non ci da informazioni riguardo relazioni di dipendenza tra i nodi. Quindi estendiamo quest'assunzione.

Minimality Assumption

- Dato $pa(X)$, un nodo X è indipendente da tutti i suoi non-discendenti.
- I nodi adiacenti sono dipendenti.

Dato un DAG G , se P è Markov allora sappiamo:


- P soddisfa un insieme di indipendenze specificate dalla struttura di G .
- se P soddisfa pure la Minimality Assumption, allora l'insieme di indipendenze è minimale, ovvero P non soddisfa altre indipendenze in G . Questo equivale a dire che tutti i nodi adiacenti sono dipendenti.

2.2 Causal Networks

Una variabile X si dice **causa** di una variabile Y se Y può cambiare in risposta a un cambiamento di X .


Causal Edge Assumption: Ogni variabile associata a un nodo è causata dalle variabili dei nodi genitori.

Un **Grafo Causale** è un DAG in cui è soddisfatta la proprietà **Causal Edge Assumption**.



X_1 causa direttamente X_2 e X_3
 X_2 causa direttamente X_3
 X_3 causa direttamente X_4
 X_1 causa indirettamente X_4

Per capire la differenza tra association flow e causation flow utilizziamo dei grafi elementari.



Il flusso di associazione esprime che due nodi del grafo sono associati o meno. Vogliamo sapere se due nodi sono (statisticamente) dipendenti o indipendenti.

Un-connected Nodes

Due nodi sconnessi non sono associati. Questo può essere dimostrato applicando la fattorizzazione.

$$\begin{aligned}
 P(X, Y) &= P(X|Y)P(Y) && \text{(probabilità composta)} \\
 &= P(X|pa(X))P(Y|pa(Y)) && \text{(fattorizzazione)} \\
 &= P(X)P(Y) && \text{indipendenza}
 \end{aligned}$$

Due nodi connessi adiacenti sono dipendenti per la **local edge assumption**.

Chain e Fork

Collider

2.3 D-Separation

Un percorso p si dice bloccato da un insieme di nodi S sse

- p contiene una chain $A \rightarrow B \rightarrow C$ o una fork $A \leftarrow B \rightarrow C$ e $B \in S$
- p contiene un collider $A \rightarrow B \leftarrow C$ e $B \notin S, de(B) \not\subseteq S$

Se l'insieme S blocca ogni percorso tra due nodi X e Y , allora X e Y si dicono **d-separated** da S , e quindi indipendenti dato S .

ESEMPLI...

La d-separazione implica l'indipendenza condizionale.

- Due variabili X e Y sono d-separate nel grafo G quando condizionate dall'insieme S ($X \perp\!\!\!\perp_G Y|S$).
- Due variabili X e Y sono indipendenti nella distribuzione p quando condizionate dall'insieme S ($X \perp\!\!\!\perp_p Y|S$).

$$X \perp\!\!\!\perp_G Y|S \Rightarrow X \perp\!\!\!\perp_p Y|S$$

Chapter 3

Causal Models

Chapter 4

Structural Causal Models

Chapter 5

Randomized Experiments

Chapter 6

Nonparametric Identification

Chapter 7

Estimation

Chapter 8

Unobserved Confounding

Chapter 9

Instrumental Variables

Chapter 10

Causal Discovery from Observational Data

Chapter 11

Transfer Learning and Transportability

Chapter 12

Counterfactuals